

AI Safety - Hackathon

SafePrompt AI: Intelligent Defense Against Prompt Injection Attacks

La idea del proyecto se enfoca en la protección sobre el uso mal intencionado de:

- Agentes de IA
 - Chats de soporte
 - Asistentes virtuales
 - Sistemas RAG
 - Agentes con Herramientas
 - Agentes empresariales conectados a bases de datos o APIs

El sistema se basa en una estructura de capas a través del procesamiento del prompt del usuario por el paso de filtros de seguridad para garantizar que el usuario no extraiga o tenga uso mal intencionado de la IA y su biblioteca de datos RAG, tools y evitar jailbreaking.

Capa 1: Clasificación de intención

Usar un LLM pequeño o un clasificador para categorizar:

- Consulta legítima
 - Intento de extracción
 - Prompt injection
 - Jailbreak
 - Ingeniería social
 - Solicitud ambigua

Capa 2: Base RAG de amenazas

Aquí sí usaría RAG.

Una base de conocimiento con:

- OWASP LLM Top 10
 - Tipos de jailbreaks
 - Casos reales
 - Patrones conocidos

Cuando llega un prompt:

1. Se vectoriza.
2. Se buscan ataques similares.
3. Se obtiene contexto.
4. Se calcula riesgo.

Capa 3: Motor de decisión

Generar una puntuación.

Ejemplo:

Riesgo	Acción
0-30	Permitir
31-60	Advertir
61-80	Bloquear parcialmente
81-100	Bloquear